泄漏受控的条件集成加权研究：项目全流程

从四个公开语料到可复现投稿包；每个方框都对应可核验的产物或脚本

① 数据获取

CIC-IDS2017：8 个 CSV，原始 2,830,743 行

NSL-KDD、UNSW-NB15、N-BaIoT（UCI 442）

URL / 检索日期 / 许可 / SHA-256 → S01

13 项摘要逐字节核验（audit_data_authenticity）

② 数据处理（六阶段审计）

标签映射 → 非有限值 → 物理范围

全局去重（前向/反向双哈希）→ 分层划分

训练侧特征选择：卡方 / 互信息 / ANOVA

2 668 729 → 研究总体；跨划分精确重叠 0

③ 建模与对照

条件加权 RCCF：softmax(−风险) 权重 + 凸组合

对照：等权 χ^2 森林、全特征等权、ExtraTrees

XGBoost、MLP（同等预算）

门控 108 组配置搜索与锁定

④ 评估

主实验：十种子；截断 53 237 条

规模阶梯 413 209 条；全语料 2 429 503 条

配对差 + 90%/95% 区间 + Bootstrap + TOST

逐类别、开放集、鲁棒性、延迟、代价敏感

⑤ 机制分析

三个可辨识性条件；边距上界 99.91% 可证

门控搜索只产生 6 个不同验证值

专家多样性剂量—反应（斜率 0.0646，r=0.749）

稀释诊断：视图差 ÷ 4 ≈ 实测差（三档成立）

⑥ 论文与交付

中英正式稿件、12 图 9 表、补充材料 S01–S30

验证闸门 53 项（数字、结构、可复现、真实性）

公开仓库 tag v1.11.2；722 个逐样本预测

投稿包与逐文件校验清单；工作日志与来源总表

核心结论：截断总体上条件加权与等权投票等价（−0.000456，TOST 两边界成立）；
全语料上转为稳定劣势（−0.005533，十种子方向一致，0.01 边界仍等价）；协议效应比聚合规则差异大一个数量级。

证据与复现：数据来源总表 · 公式来源与核验 · 数据处理代码与流程 · 补充材料 S01–S30 · scripts/verify_all_v8.py（53 项闸门）