

泄漏受控的条件集成加权研究：项目全流程

从四个公开语料到可复现投稿包；每个方框都对应可核验的产物或脚本

① 数据获取

CIC-IDS2017: 8 个 CSV, 原始 2,830,743 行
NSL-KDD、UNSW-NB15、N-BalIoT (UCI 442)
URL / 检索日期 / 许可 / SHA-256 → S01
13 项摘要逐字节核验 (audit_data_authenticity)

② 数据处理 (六阶段审计)

标签映射 → 非有限值 → 物理范围
全局去重 (前向/反向双哈希) → 分层划分
训练侧特征选择: 卡方 / 互信息 / ANOVA
2 668 729 → 研究总体; 跨划分精确重叠 0

③ 建模与对照

条件加权 RCCF: $\text{softmax}(-\text{风险})$ 权重 + 凸组合
对照: 等权 χ^2 森林、全特征等权、ExtraTrees
XGBoost、MLP (同等预算)
门控 108 组配置搜索与锁定

④ 评估

主实验: 十种子; 截断 53 237 条
规模阶梯 413 209 条; 全语料 2 429 503 条
配对差 + 90%/95% 区间 + Bootstrap + TOST
逐类别、开放集、鲁棒性、延迟、代价敏感

⑤ 机制分析

三个可辨识度条件; 边距上界 99.91% 可证
门控搜索只产生 6 个不同验证值
专家多样性剂量—反应 (斜率 0.0646, $r=0.749$)
稀释诊断: 视图差 $\div 4 \approx$ 实测差 (三档成立)

⑥ 论文与交付

中英正式稿件、11 图 8 表、补充材料 S01–S30
验证闸门 51 项 (数字、结构、可复现、真实性)
公开仓库 tag v1.11.0; 722 个逐样本预测
投稿包 783 文件; 工作日志与来源总表

核心结论: 截断总体上条件加权与等权投票等价 (-0.000456 , TOST 两边界成立);

全语料上转为稳定劣势 (-0.005533 , 十种子方向一致, 0.01 边界仍等价); 协议效应比聚合规则差异大一个数量级。

证据与复现: 数据来源总表 · 公式来源与核验 · 数据处理代码与流程 · 补充材料 S01–S30 · scripts/verify_all_v8.py (51 项闸门)